

Lista 02 - Machine Learning IMPA

Pedro Barbosa Bahia

20 de fevereiro de 2026

Conteúdo

Exercício 4

Parte (a)

(a)

Explique o que essa visualização representa e interprete os resultados obtidos.

A visualização da figura "attention.html" representa a matriz que correlaciona cada uma das 32 primeiras amostras do conjunto de teste às outras amostras. O valor de cada aresta é dado pelo produto interno entre as vetorizações TF-IDF de cada par de notícias, ou seja, a similaridade entre dois textos dadas suas palavras ponderadas pelo inverso da frequência.

O código que gera esta visualização:

```
1 seq = X_test[:32,:]
2 b = seq.toarray()
3 att = b@b.T
4 att = att.reshape(1,1,32,32)
5 att = torch.tensor(att)
6 counts = [0,0,0,0]
7 tokens = []
8 for i in y_test[:32]:
9     token = target_names[i] + ' ' + str(counts[i])
10    tokens.append(token)
11    counts[i]+=1
12 head_view((att,), tokens)
```

A matriz de atenção att é calculada como $att = b \cdot b^T$, onde b são as representações TF-IDF das 32 primeiras amostras. Esta operação produz uma matriz 32x32 onde cada entrada (i, j) representa a similaridade cosseno entre as amostras i e j .

Parte (b)

(b-i)

Sejam $u, v \in \mathbb{R}^d$, P_u a projeção ortogonal sobre o espaço gerado por u . Mostre que $P_u(v) = \frac{\langle u, v \rangle}{\|u\|^2} u$.

A projeção do vetor v em u tem duas componentes: direção e magnitude. A direção é dada pelo vetor de norma unitária na direção de u :

$$\hat{u} = \frac{u}{\|u\|}$$

A magnitude é dada pela componente de v , v_u , tal que $v - v_u = v_{\perp u}$ e $v_{\perp u}$ é ortogonal a u . v_u é também a projeção escalar de v em u , cuja definição é:

$$v_u = v \cdot \hat{u} = \frac{v \cdot u}{\|u\|}$$

Attention Visualization Summary

Interactive Attention Matrix Visualization

This HTML visualization shows:

- Pairwise attention weights between 32 news articles
- Each cell (i,j) represents similarity between articles i and j
- Darker colors indicate stronger attention/similarity
- Articles are labeled by category (comp.graphics, sci.space, alt.atheism, rec.autos)

Two versions are generated:

1. Initial TF-IDF similarity (item a)
2. Learned attention after training with proper initialization (item f)

The visualization demonstrates how the attention mechanism learns to better distinguish between different news categories.

Note: The original HTML file contains an interactive D3.js visualization that allows exploration of attention weights between article pairs.

Figura 1: Descrição da visualização de atenção TF-IDF

Assim:

$$\begin{aligned} P_u(v) &= v_u \cdot \hat{u} \\ &= \frac{v \cdot u}{\|u\|} \cdot \frac{u}{\|u\|} \\ &= \frac{\langle v, u \rangle}{\|u\|^2} \cdot u \end{aligned}$$

(b-ii)

Considere a definição de cosseno entre dois vetores $\cos(u, v) := \frac{\langle u, v \rangle}{\|u\| \|v\|}$. Use a fórmula do item (b-i) para relacionar essa definição de cosseno com o cosseno de um ângulo (construa um triângulo retângulo com v e $P_u(v)$).

Partindo da definição:

$$\cos(u, v) := \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

Substituindo a relação encontrada em (b-i):

$$\begin{aligned}
\cos(u, v) &= P_u(v) \cdot \frac{\|u\|}{\|v\|} \cdot u \\
&= \frac{P_u(v)}{\hat{u}\|v\|} \\
&= \frac{\|P_u(v)\|\hat{u}}{\|v\|\hat{u}} \\
&= \frac{\|P_u(v)\|}{\|v\|} \\
&= \frac{\text{Cateto Adjacente}}{\text{Hipotenusa}}
\end{aligned}$$

(b-iii)

Mostre que, se $u_1, v_1, u_2, v_2 \in \mathbb{R}^d$ com $\|u_1\| = \|v_1\| = \|u_2\| = \|v_2\| = 1$, então $\cos(u_1, v_1) \geq \cos(u_2, v_2) \iff \|u_1 - v_1\| \leq \|u_2 - v_2\|$. Argumente que cos pode ser usado como uma medida de similaridade quando os vetores em consideração têm norma 1.

Assumindo:

$$\begin{aligned}
\cos(u_1, v_1) &\geq \cos(u_2, v_2) \\
\langle u_1, v_1 \rangle &\geq \langle u_2, v_2 \rangle \\
P_{u_1}(v_1) &\geq P_{u_2}(v_2)
\end{aligned}$$

Calculando a norma da diferença $\|u_1 - v_1\|$:

$$\begin{aligned}
\|u_1 - v_1\| &= [(\|u_1\| + \| -v_1\|)^2 - 2\|P_{u_1}(v_1)\|]^{\frac{1}{2}} \\
&= [1 + 1 - 2\|P_{u_1}(v_1)\|]^{\frac{1}{2}} \\
&= [2 - 2\|P_{u_1}(v_1)\|]^{\frac{1}{2}}
\end{aligned}$$

Analogamente para $\|u_2 - v_2\|$:

$$\|u_2 - v_2\| = [2 - 2\|P_{u_2}(v_2)\|]^{\frac{1}{2}}$$

Portanto, se $\|P_{u_1}(v_1)\| \geq \|P_{u_2}(v_2)\|$, então $\|u_1 - v_1\| \leq \|u_2 - v_2\|$, já que $[1 - \|P_{u_1}(v_1)\|] \leq [1 - \|P_{u_2}(v_2)\|]$. O sentido oposto da prova é feito de maneira análoga.

Conclui-se que o cosseno pode ser usado como uma métrica de similaridade equivalente à norma da diferença (distância), com escala variando de 1 (vetores com mesma direção e sentido) a -1 (vetores com sentidos opostos), sendo 0 para vetores ortogonais.

(b-iv)

Em vista do item anterior, aponte diferenças entre a noção de similaridade capturada por $\|u - v\|$ e $\cos(u, v)$. Em que casos seria mais vantajoso usar cada uma dessas noções de similaridade?

A métrica da norma da diferença tem seus valores proporcionais à magnitude dos vetores avaliados. Enquanto isso, a métrica do cosseno pressupõe vetores unitários e é agnóstica à magnitude.

Assim, em um caso em que apenas a direção importa, o cosseno é preferível. Em casos em que a magnitude também é relevante, a métrica da norma é preferível ao cosseno.

Parte (c)

(c)

Note que a rede não está aprendendo. Explique qual é o problema e exponha evidências de que ele realmente está acontecendo.

A inicialização incorreta da matriz de pesos é a causa do não aprendizado da rede. Como não normalizamos os pesos, sua variância era grande o suficiente para gerar valores com alta magnitude que, ao passar pelo softmax, resulta em valores próximos a 1 com gradientes próximos a 0.

O problema pode ser observado através das evidências experimentais:

1. **Perda constante:** O gráfico da função perda mostra que ela permanece praticamente constante ao longo das épocas, indicando ausência de aprendizado.
2. **Gradientes próximos a zero:** Os histogramas dos gradientes das matrizes A_K e A_Q mostram que a maioria dos gradientes está concentrada em torno de zero, evidenciando o problema do gradiente que desaparece.
3. **Saída do softmax saturada:** O histograma da saída do softmax mostra valores próximos a 1, indicando saturação da função.

O código que demonstra esse problema:

```
# Inicialização sem normalização adequada
A_K = torch.randn((D,D)).cuda() # SEM *init_scale(D)
A_Q = torch.randn((D,D)).cuda() # SEM *init_scale(D)

# Loop de treinamento
for epoch in range(n_epochs):
    # ... treinamento ...
    att = softmax((K.T@Q)/(D**(1/2)))
    loss = -cos(att,truth).mean()
    loss.backward()
```




Figura 2: Função perda sem inicialização adequada - sem aprendizado

Parte (d)

(d)

Corrija o problema identificado no item anterior e demonstre que a rede agora consegue aprender.

De fato, adicionar um termo na inicialização dos parâmetros permitiu o aprendizado e subsequente redução da função perda. Isso ocorre pois o valor pelo qual multiplicamos os pesos iniciais é $(2/D)^{1/2}$, sendo D o tamanho da camada. Isso reduz a variância dos parâmetros e evita que valores muito grandes sejam passados ao softmax e tenham seu gradiente próximo a zero.

A correção implementada:

```
def init_scale(fan_in):
    return (2/fan_in)**0.5

# Inicialização com normalização adequada
A_K = torch.randn((D,D)).cuda() * init_scale(D) # COM *init_scale(D)
A_Q = torch.randn((D,D)).cuda() * init_scale(D) # COM *init_scale(D)
```

As evidências do aprendizado bem-sucedido incluem:

1. **Redução da perda:** O gráfico da função perda agora mostra uma tendência decrescente clara ao longo das épocas.
2. **Gradientes não-zero:** Os histogramas dos gradientes mostram distribuições mais amplas, indicando gradientes efetivos para o aprendizado.




Figura 3: Distribuições dos pesos iniciais A_K e A_Q

3. **Distribuição melhorada do softmax:** A saída do softmax apresenta uma distribuição mais balanceada, não saturada.

Parte (e)

(e-i)

A camada de auto-atenção (self-attention) pode ser representada matematicamente como

$$\text{Sa}[X] = V[X] \cdot \text{Softmax}\left(\frac{K[X]^T Q[X]}{\sqrt{D}}\right)$$

Mostre que, se $K[X]$ e $Q[X]$ têm entradas gaussianas com média zero e variância σ^2 , todas independentes entre si, cada entrada de $K[X]^T Q[X]$ tem variância $\sigma^4 D$. Use esse fato para argumentar a favor da divisão por $\sqrt{D}$.

Seja $Z = K[X]^T Q[X] = \sum_{i=1}^D K_i[X]^T Q_i[X]$

Calculando a Esperança $\mathbb{E}(Z)$:

$$\begin{aligned} \mathbb{E}(Z) &= \mathbb{E}(K[X]^T Q[X]) \\ &= \mathbb{E}(K[X]^T) \cdot \mathbb{E}(Q[X]) \quad (\text{devido à independência}) \\ &= 0 \cdot 0 = 0 \end{aligned}$$




Figura 4: Histogramas dos gradientes de A_K e A_Q na primeira época (sem inicialização adequada)

Calculando a Variância $\mathbb{V}(Z)$:

$$\begin{aligned}
 \mathbb{V}(Z) &= \mathbb{V}(K[X]^T Q[X]) \\
 &= \mathbb{E}([K[X]^T Q[X] - \mathbb{E}(K[X]^T Q[X])]^2) \\
 &= \mathbb{E}((K[X]^T Q[X])^2) - (\mathbb{E}(K[X]^T Q[X]))^2 \\
 &= \mathbb{E}((K[X]^T)^2) \cdot \mathbb{E}((Q[X])^2)
 \end{aligned}$$

Como $\mathbb{V}(K[X]^T) = \mathbb{E}((K[X]^T)^2) - (\mathbb{E}(K[X]^T))^2$:

$$\mathbb{V}(K[X]^T) = \mathbb{E}((K[X]^T)^2)$$

Logo, $\mathbb{V}(Z) = \mathbb{V}(K[X]^T) \cdot \mathbb{V}(Q[X])$

A variância de cada termo na soma é $\sigma^2 \cdot \sigma^2 = \sigma^4$. Somando sobre as D dimensões:

$$\mathbb{V}(Z)_{ij} = \sum_{i=1}^D \sigma^4 = D\sigma^4$$

Para normalizarmos e obtermos variância unitária, devemos dividir pela raiz da variância. Como σ é comum a ambos os termos da divisão, apenas $\sqrt{D}$ aparece no denominador.

(e-ii)

É necessário assumir que as entradas são gaussianas para chegar a essa conclusão? Caso contrário, é necessário que sejam identicamente distribuídas?

Não foi necessário assumir distribuição gaussiana das variáveis, apenas independência e mesmos valores de média e variância. Os mesmos resultados seriam obtidos caso as variáveis não seguissem a mesma distribuição, mas mantivessem a independência e os valores de média e variância constantes.




Figura 5: Saída do softmax na primeira época (sem inicialização adequada)

Parte (f)

(f)

Usando o comando `head_view`, visualize a similaridade par a par que a rede associa à sequência de notícias correspondente a `X_test[:32]`, `y_test[:32]`. Compare com a visualização realizada no item (a) e interprete o resultado.

O resultado do presente `head_view` apresenta relações entre amostras da mesma classe mais fortes que o `head_view` do item (a), indicando o impacto do treinamento na definição da similaridade.

O código que gera a visualização após o treinamento:

```
# Calculando a nova matriz de atenção com os pesos treinados
att = (A_K.cpu().detach().numpy()@b.T ).T @ (A_Q.cpu().detach().numpy()@b.T )
att = att.reshape(1,1,32,32)
att = torch.tensor(att)
head_view((att,), tokens)
```

A comparação entre as visualizações mostra:

1. **Visualização inicial (item a):** Utiliza similaridade TF-IDF pura ($b \cdot b^T$), onde a similaridade é baseada apenas na sobreposição de termos ponderados.
2. **Visualização após treinamento (item f):** Utiliza as matrizes aprendidas A_K e A_Q , calculando $(A_K \cdot b^T)^T \cdot (A_Q \cdot b^T)$.




Figura 6: Função perda com inicialização adequada - aprendizado bem-sucedido

3. **Melhoria observada:** A rede aprendeu a criar representações que aumentam a similaridade entre artigos da mesma categoria, demonstrando que o mecanismo de atenção pode aprender padrões mais sofisticados que a simples sobreposição de termos.

Esta comparação demonstra a eficácia do treinamento da rede neural em aprender representações mais discriminativas para a similaridade entre textos, superando métricas baseadas puramente em estatísticas de termos como TF-IDF.




Figura 7: Distribuições dos pesos iniciais A_K e A_Q com inicialização adequada




Figura 8: Histogramas dos gradientes de A_K e A_Q na primeira época (com inicialização adequada)




Figura 9: Saída do softmax na primeira época (com inicialização adequada)




Figura 10: Comparação entre a visualização de atenção inicial (TF-IDF) e após o treinamento (atenção aprendida)