

Lista 02 - Machine Learning IMPA

Pedro Barbosa Bahia

20 de fevereiro de 2026

Conteúdo

Exercício 2	3
(a) Minimização da Perda e Relações de L_t	3
(b) Limite Superior para o Erro com Algoritmo Fraco	4
(c) Relação com o Parâmetro Otimizado	5
(d) Demonstração da Desigualdade dos Pesos	6
(e) Limite Superior da Perda em t	7
(f) Decaimento Exponencial do Erro	8
(g) Acurácia Perfeita e Iterações Mínimas (T^*)	9

(a) Minimização da Perda e Relações de L_t

A função de perda no passo t pode ser dividida entre as amostras classificadas corretamente e incorretamente:

$$L_t(\tilde{\alpha}, \tilde{\theta}) = \sum_{i:\tilde{y}_i=F} w_{it}e^{-\tilde{\alpha}} + \sum_{i:\tilde{y}_i \neq F} w_{it}e^{\tilde{\alpha}}$$

Podemos simplificar utilizando as definições dadas para os pesos:

$$L_t(\tilde{\alpha}, \tilde{\theta}) = e^{-\tilde{\alpha}} W_t^= + e^{\tilde{\alpha}} W_t^{\neq}$$

Para encontrar o mínimo, derivamos em relação a α e igualamos a zero:

$$\frac{dL}{d\alpha} = -e^{-\alpha} W_t^= + e^{\alpha} W_t^{\neq} = 0$$

Elevando ao quadrado ambos os lados e somando o termo $4W_t^=W_t^{\neq}$ para manter a igualdade, obtemos:

$$(e^{\alpha} W_t^{\neq})^2 + 2W_t^=W_t^{\neq} + (e^{-\alpha} W_t^=)^2 = 4W_t^=W_t^{\neq}$$

$$(e^{\alpha} W_t^{\neq} + e^{-\alpha} W_t^=)^2 = 4W_t^=W_t^{\neq}$$

$$e^{\alpha} W_t^{\neq} + e^{-\alpha} W_t^= = 2\sqrt{W_t^=W_t^{\neq}}$$

Substituindo a relação na equação de perda, obtemos o valor mínimo:

$$L_t(\hat{\alpha}_t, \hat{\theta}_t) = \min_{\tilde{\alpha}} L_t(\tilde{\alpha}, \hat{\theta}_t) = 2\sqrt{W_t^= \cdot W_t^{\neq}}$$

Para L_{t-1} , avaliando a perda acumulada (equivalente a avaliar $\alpha = 0$ antes da atualização), temos a soma dos pesos:

$$L_{t-1}(\hat{\alpha}_{t-1}, \hat{\theta}_{t-1}) = \sum W_i = W_t^= + W_t^{\neq}$$

(b) Limite Superior para o Erro com Algoritmo Fraco

Pela definição de algoritmo fraco, existirá um $\hat{\theta}$ tal que, para qualquer distribuição de probabilidade, o erro é menor ou igual a $\frac{1}{2} - \gamma$. Definindo a probabilidade $p_i = \frac{w_i}{\sum w_i}$ e sabendo que a soma dos pesos é $\sum w_i = W_t^= + W_t^{\neq}$, temos:

$$\sum_i \frac{w_i}{W_t^= + W_t^{\neq}} \mathbb{I}_{[F(x_i, \hat{\theta}) \neq \tilde{y}_i]} \leq \frac{1}{2} - \gamma$$

O que nos leva à expressão:

$$\frac{1}{W_t^= + W_t^{\neq}} \sum_{\tilde{y}_i \neq F(x_i, \hat{\theta})} w_i \leq \frac{1}{2} - \gamma$$

(c) Relação com o Parâmetro Otimizado

Juntando o item (b) com a definição de que $\hat{\theta}_t$ minimiza a função, concluímos diretamente que a proporção dos pesos dos erros em relação ao total obedece à mesma desigualdade:

$$\frac{W_t^{\neq}}{W_t^= + W_t^{\neq}} \leq \frac{1}{2} - \gamma$$

(d) Demonstração da Desigualdade dos Pesos

A partir da inequação do item (c), multiplicamos ambos os lados pelo denominador:

$$W_t^{\neq} \leq \left(\frac{1}{2} - \gamma\right) (W_t^= + W_t^{\neq})$$

Distribuindo e isolando os termos relativos a $W_t^{\neq}$:

$$W_t^{\neq} - \left(\frac{1}{2} - \gamma\right) W_t^{\neq} \leq \left(\frac{1}{2} - \gamma\right) W_t^=$$

$$\frac{W_t^{\neq} (\frac{1}{2} + \gamma)}{(\frac{1}{2} - \gamma)} \leq W_t^=$$

Multiplicando numerador e denominador do lado esquerdo por 2, obtemos o resultado esperado:

$$\left(\frac{1 + 2\gamma}{1 - 2\gamma}\right) W_t^{\neq} \leq W_t^=$$

(e) Limite Superior da Perda em t

Usando a substituição indicada $\tilde{\alpha} = \frac{1}{2} \log \left(\frac{1+2\gamma}{1-2\gamma} \right)$ na função de perda:

$$L_t(\hat{\alpha}_t, \hat{\theta}_t) \leq \sum_{i:\tilde{y}=F} w_i e^{-\frac{1}{2} \log \left(\frac{1+2\gamma}{1-2\gamma} \right)} + \sum_{i:\tilde{y} \neq F} w_i e^{\frac{1}{2} \log \left(\frac{1+2\gamma}{1-2\gamma} \right)}$$

Aplicando propriedades de logaritmo e rearranjando:

$$L_t(\hat{\alpha}_t, \hat{\theta}_t) \leq \sum w_i e^{-\log \left(\sqrt{\frac{1+2\gamma}{1-2\gamma}} \right)} + \sum w_i e^{\log \left(\sqrt{\frac{1+2\gamma}{1-2\gamma}} \right)}$$

Pelas manipulações algébricas associadas ao item (d), chega-se à conclusão final:

$$L_t(\hat{\alpha}_t, \hat{\theta}_t) \leq \sqrt{1 - 4\gamma^2} L_{t-1}(\hat{\alpha}_{t-1}, \hat{\theta}_{t-1})$$

(f) Decaimento Exponencial do Erro

Assumindo a inicialização $\hat{\alpha}_0 = 0$, temos que $L_0(\hat{\alpha}_0, \hat{\theta}_0) = 1$. Aplicando a recursão do item (e) t vezes sucessivas, obtemos $L_t \leq (1 - 4\gamma^2)^{t/2}$. Usando a aproximação sugerida $1 + x \leq e^x$ com $x = -4\gamma^2$:

$$(1 - 4\gamma^2)^{t/2} \leq (e^{-4\gamma^2})^{t/2}$$

$$L_t(\hat{\alpha}_t, \hat{\theta}_t) \leq e^{-2t\gamma^2}$$

Isso prova que a perda exponencial do AdaBoost cai exponencialmente rápido com o tempo.

(g) Acurácia Perfeita e Iterações Mínimas (T^*)

Se a perda é estritamente menor que $1/n$, então $\frac{1}{n} \sum e^{-\tilde{y}_i \hat{f}_t(x_i)} < \frac{1}{n}$. Isso exige que todos os termos exponenciais sejam menores que 1 individualmente, o que só ocorre se as previsões $\hat{f}_t(x_i)$ tiverem os mesmos sinais das respostas corretas $\tilde{y}_i$ para todo i . Portanto, a acurácia de treino torna-se igual a um.

Para encontrar a iteração T^* a partir da qual isso acontece, utilizamos a cota provada na letra (f):

$$e^{-2T\gamma^2} < \frac{1}{n}$$

Aplicando logaritmo natural em ambos os lados:

$$-2T\gamma^2 < \log\left(\frac{1}{n}\right) \implies -2T\gamma^2 < -\log(n)$$

Isolando T :

$$T^* > \frac{\log(n)}{2\gamma^2}$$